

Universitatea Națională de Știință și Tehnologie POLITEHNICA București
Facultatea de Electronică, Telecomunicații și Tehnologia Informației

**Clasificarea tipurilor de sol: o analiză comparativă între
trei metode de clasificare a imaginilor**

Proiect CV2

Studenti:
Andrei-Laurențiu CIURTIN
Elena RADU
411-SIVA

Anul 2026

Cuprins

Lista figurilor	3
Lista acronimelor	4
Introducere	5
Obiectivul lucrării	5
1. Fundamente Teoretice	6
1.1. Prezentarea, Morfologia și Distribuția Setului de Date <i>Soil Types</i>	6
1.2. Fundamente teoretice ale metodei Bag of Visual Words (BoVW)	6
1.3. Clasificarea cu Random Forest	7
1.4. Arhitectura ResNet-18	7
1.5. Arhitectura DenseNet	7
2. Desfășurarea experimentală	8
2.1. Bag of Visual Words si Random Forest	8
2.2. ResNet-18	9
2.2.1. Dinamică de antrenare și analiza funcției de pierdere	10
2.2.2. Evaluare pe setul de test și analiza rezultatelor	11
2.3. DenseNet121	12
2.3.1. Analiza curbelor de antrenare	12
2.3.2. Analiza matricei de confuzie	12
Concluzii și direcții viitoare	14
Direcții viitoare	14
Bibliografie	15

Lista figurilor

2.1. Matricea de confuzie - Random Forest.	9
2.2. Raportul de clasificare - Random Forest.	9
2.3. Reprezentarea funcției de pierdere pentru antrenare și validare.	10
2.4. Matricea de confuzie - ResNet18.	11
2.5. Raportul de clasificare - ResNet18.	11
2.6. Reprezentarea funcției de pierdere pentru antrenare și validare - DenseNet121. .	12
2.7. Matricea de confuzie - DenseNet121.	13
2.8. Raportul de clasificare - DenseNet121.	13

Lista acronimelor

AI = Artificial Intelligence
BoVW = Bag of Visual Words
CNN = Convolutional Neural Network
CV = Computer Vision
DL = Deep Learning
FC = Fully Connected
GPU = Graphics Processing Unit
KNN = K-Nearest Neighbors
ML = Machine Learning
RGB = Red Green Blue
ReLU = Rectified Linear Unit
SIFT = Scale-Invariant Feature Transform
SURF = Speeded-Up Robust Features
TF-IDF = Term Frequency–Inverse Document Frequency

Introducere

Precizia în determinarea și clasificarea tipurilor de sol reprezintă un element esențial în domenii precum agricultura, studiile geologice, ingineria civilă și gestionarea ecosistemelor. În mod tradițional, evaluarea caracteristicilor solului se realizează prin prelevarea fizică a probelor și analizarea acestora în condiții de laborator, utilizând metode spectroscopice, analize chimice și evaluări granulometrice detaliate. Deși aceste tehnici oferă un nivel ridicat de acuratețe în identificarea proprietăților fizico-chimice ale solului, ele implică un consum considerabil de timp și resurse financiare, fiind totodată influențate de posibile erori de eșantionare sau manipulare a probelor. În contextul dezvoltării accelerate a domeniului Computer Vision și al algoritmilor de inteligență artificială, analiza automată a texturilor și culorilor solului pe baza imaginilor digitale a devenit o direcție de cercetare de interes major, datorită potențialului de automatizare și eficientizare a proceselor de analiză pedologică.

Obiectivul lucrării

Obiectivul principal al lucrării constă în analiza arhitecturii, procesului de antrenare și performanței unor modele predictive distincte. Prima abordare investigată aparține paradigmei clasice de Machine Learning și combină algoritmul Random Forest cu metoda de extragere a caracteristicilor Bag of Visual Words (BoVW).¹ În paralel, sunt analizate arhitecturi moderne de rețele neurale convoluționale profunde (Deep Learning), precum ResNet-18 și DenseNet, adaptate prin utilizarea tehnicilor de Transfer Learning, Partial Freezing și augmentare stochastică a datelor.

Prin compararea acestor metodologii pe același set de date, lucrarea urmărește evidențierea atât a performanțelor predictive obținute, cât și a modului în care algoritmi procesează și interpretează caracteristicile texturale ale solului. Solurile și substraturile geologice prezintă un grad ridicat de variabilitate, determinat de factori precum umiditatea, iluminarea, compoziția organică și structura granulometrică, aspecte care conduc la suprapuneri semnificative în spațiul cromatic și textural. În acest context, analiza comparativă dintre metodele clasice bazate pe descrierea caracteristicilor vizuale și rețelele convoluționale capabile să învețe reprezentări semantice complexe, precum ResNet-18 și DenseNet, oferă o perspectivă relevantă asupra potențialului sistemelor automate de clasificare în domeniul pedologiei.

Capitolul 1

Fundamente Teoretice

1.1 Prezentarea, Morfologia și Distribuția Setului de Date *Soil Types*

Baza experimentală a acestui proiect este reprezentată de setul de date *Soil Types*, compus din imagini digitale reprezentative pentru mai multe categorii de sol. Datasetul include cinci clase distincte: *Black Soil* (soluri negre, bogate în materie organică), *Cinder Soil* (soluri vulcanice cu conținut ridicat de cenușă), *Laterite Soil* (soluri roșiatice bogate în oxizi de fier și aluminiu), *Peat Soil* (soluri turboase cu conținut ridicat de materie organică parțial descompusă) și *Yellow Soil* (soluri cu nuanțe gălbui determinate de compuși ai fierului).

Din punct de vedere cantitativ, setul de date conține 156 de imagini, o dimensiune redusă în raport cu cerințele tipice ale învățării profunde. Totuși, distribuția claselor este relativ echilibrată, aspect esențial pentru stabilitatea procesului de antrenare și pentru evitarea bias-ului către clasa majoritară.

Clasă de sol	Caracteristică principală	Nr. imagini	Proporție
Black Soil	Sol bogat în materie organică	37	23.71%
Cinder Soil	Sol vulcanic, textură aspră	30	19.23%
Laterite Soil	Sol bogat în oxizi de fier	30	19.23%
Peat Soil	Sol organic, structură fibroasă	30	19.23%
Yellow Soil	Sol argilos, nuanțe gălbui	29	18.58%

Tabela 1.1: Distribuția claselor din setul de date *Soil Types*

Distribuția relativ uniformă reduce riscul apariției unui clasificator dominant pe clasa majoritară și contribuie la învățarea unor caracteristici discriminative reale între clase.

Imaginile sunt stocate în format *.jpg*, având rezoluții variabile, de exemplu 160×144 pixeli, cu trei canale de culoare RGB. Valorile pixelilor sunt reprezentate pe 8 biți (uint8), în intervalul 0–255, constituind reprezentarea brută utilizată ulterior în pipeline-urile de procesare.

1.2 Fundamente teoretice ale metodei Bag of Visual Words (BoVW)

Metoda Bag of Visual Words (BoVW) reprezintă o paradigmă clasică de extragere a caracteristicilor, inspirată din modelul Bag of Words utilizat în procesarea limbajului natural. În această analogie, imaginile sunt tratate ca „documente vizuale”, iar descriptorii locali sunt echivalenți cu „cuvinte vizuale” [1].

Procesul BoVW include următoarele etape principale:

- **Extragerea descriptorilor locali:** identificarea punctelor de interes și reprezentarea lor prin vectori numerici ce descriu variații locale de intensitate.

- **Construirea vocabularului vizual:** utilizarea algoritmului K-Means pentru gruparea descriptorilor în clustere, fiecare centroid reprezentând un cuvânt vizual.
- **Reprezentarea imaginilor:** transformarea fiecărei imagini într-o histogramă a frecvențelor cuvintelor vizuale.
- **Normalizarea reprezentării:** ajustarea frecvențelor pentru reducerea influenței caracteristicilor comune și accentuarea celor discriminative.

Această reprezentare permite conversia imaginilor din spațiul pixelilor într-un spațiu vectorial adecvat clasificării.

1.3 Clasificarea cu Random Forest

După transformarea imaginilor în vectori BoVW, clasificarea este realizată prin algoritmul Random Forest, un ansamblu de arbori de decizie antrenati pe subseturi bootstrap ale datelor.

Modelul utilizează atât bootstrap aggregating, cât și selecția aleatoare a subseturilor de caracteristici la fiecare nod, reducând corelația dintre arbori și îmbunătățind generalizarea [2].

Decizia finală este obținută prin vot majoritar între toți arborii din ansamblu. Această abordare este eficientă pentru spații de caracteristici sparse și de dimensionalitate ridicată, specifice reprezentării BoVW.

În cadrul experimentelor, acest pipeline a obținut o acuratețe de aproximativ 80.85% pe setul de test, demonstrând eficiența metodelor clasice de viziune computațională.

1.4 Arhitectura ResNet-18

A doua abordare utilizează o rețea neuronală convoluțională profundă de tip ResNet-18, bazată pe învățarea reziduală. Aceasta introduce conexiuni skip connection, care permit propagarea directă a informației și reduc problema degradării gradientului în rețele adânci [3].

Modelul procesează imagini de dimensiune 224×224 pixeli și este structurat în mai multe blocuri convoluționale urmate de pooling global și un strat complet conectat pentru clasificare. Utilizarea ResNet-18 este justificată de dimensiunea redusă a datasetului, reducând riscul de overfitting și asigurând un echilibru între complexitate și capacitate de generalizare.

1.5 Arhitectura DenseNet

DenseNet (Densely Connected Convolutional Networks) reprezintă o arhitectură profundă în care fiecare strat primește ca intrare concatenarea tuturor ieșirilor straturilor precedente.

Această conectivitate densă îmbunătățește fluxul gradientului, reduce problema dispariției acestuia și permite reutilizarea eficientă a caracteristicilor învățate. Comparativ cu arhitecturile tradiționale, DenseNet poate atinge performanțe ridicate cu un număr mai mic de parametri, ceea ce îl face potrivit pentru scenarii cu date limitate [4].

Capitolul 2

Desfășurarea experimentală

2.1 Bag of Visual Words si Random Forest

În cadrul acestei etape experimentale a fost implementată o metodologie clasică de clasificare a imaginilor bazată pe reprezentarea Bag of Visual Words (BoVW), urmată de un clasificator de tip Random Forest. Întregul flux experimental pornește de la citirea și organizarea datasetului *Soil Types*, fiecare imagine fiind asociată unei clase corespunzătoare pe baza structurii directoarelor.

Imaginile sunt preprocesate prin standardizare, incluzând conversia în spațiul de culoare RGB, redimensionarea la o rezoluție fixă și normalizarea valorilor pixelilor în intervalul $[0, 1]$. Această etapă asigură consistența datelor de intrare și reduce variațiile cauzate de diferențele de rezoluție sau intensitate cromatică.

Ulterior, fiecare imagine este împărțită în regiuni locale (patch-uri) de dimensiune fixă, din care sunt extrase „cuvinte vizuale” prin vectorizarea patch-urilor. La nivelul întregului set de date au fost generate 275.184 de astfel de cuvinte vizuale, care constituie baza pentru construirea vocabularului.

Pentru reprezentarea globală a imaginilor a fost utilizat un vocabular vizual de dimensiune 100, obținut prin aplicarea algoritmului K-Means asupra descriptorilor extrași. Acest parametru determină granularitatea reprezentării BoVW, fiecare centroid corespunzând unui „cuvânt vizual” din spațiul caracteristicilor.

În urma procesului de agregare, fiecare imagine este transformată într-un vector de dimensiune 100, corespunzător histogramei de frecvență a cuvintelor vizuale. Astfel, setul de date final utilizat pentru clasificare are forma (156, 100), unde fiecare exemplu reprezintă distribuția statistică a descriptorilor locali.

Pentru evaluarea modelului, datele sunt împărțite în mod stratificat în set de antrenare și set de test, menținând distribuția claselor. Setul de antrenare conține 109 imagini, iar setul de test 47 de imagini, cu o distribuție relativ echilibrată între clase.

Clasificarea este realizată utilizând un model Random Forest cu 100 de estimatori ($n_estimators = 100$). Fiecare arbore este antrenat pe subseturi diferite ale datelor, iar predicția finală este obținută prin vot majoritar.

Modelul obține o acuratețe de aproximativ 80% pe setul de test, demonstrând eficiența reprezentării BoVW în combinație cu un clasificator bazat pe ansamblu.

Pentru analiza performanței au fost utilizate matricea de confuzie și raportul de clasificare, evidențiind distribuția erorilor între clasele de sol și capacitatea modelului de a diferenția categoriile cu caracteristici texturale similare.

Analizând matricea de confuzie, se observă că *Black Soil* și *Yellow Soil* sunt cele mai bine clasificate de model, aceste tipuri de sol fiind ușor de diferențiat datorită caracteristicilor cromatice distinctive. În schimb, pentru celelalte clase de sol, discriminarea este mai dificilă, variațiile fiind determinate în principal de diferențe subtile de textură și consistență. Se remarcă, de asemenea, o tendință a clasificatorului de a confunda frecvent clasa *Peat Soil* cu *Black Soil*, fenomen explicabil prin similaritatea cromatică dintre aceste categorii, întrucât

anumite exemple din clasa *Black Soil* prezintă nuanțe mai închise de tip brun, apropiate de cele specifice solurilor turboase.




Figura 2.1: Matricea de confuzie - Random Forest.

Classification Report:				
	precision	recall	f1-score	support
0	0.77	0.91	0.83	11
1	0.70	0.78	0.74	9
2	1.00	0.89	0.94	9
3	0.67	0.44	0.53	9
4	0.90	1.00	0.95	9
accuracy			0.81	47
macro avg	0.81	0.80	0.80	47
weighted avg	0.81	0.81	0.80	47

Figura 2.2: Raportul de clasificare - Random Forest.

2.2 ResNet-18

În această etapă experimentală este utilizată o arhitectură de tip rețea neuronală convoluțională profundă, ResNet-18, cu ponderi pre-antrenate pe ImageNet, adaptată ulterior problemei de clasificare a tipurilor de sol prin tehnica de transfer learning. Spre deosebire de abordarea clasică bazată pe BoVW, această metodă operează direct asupra imaginilor brute, permițând extragerea automată a reprezentărilor ierarhice de caracteristici.

Imaginile sunt redimensionate la 224×224 pixeli și normalizate folosind statisticile standard ale datasetului ImageNet. Pentru a îmbunătăți capacitatea de generalizare a modelului, în

etapa de antrenare este aplicată augmentare de date, incluzând transformări precum random crop, rotații, flip orizontal și variații de luminozitate și contrast.

Pentru împărțirea datasetului este utilizat un split stratificat de tip 70% antrenare, 15% validare și 15% test, menținând distribuția claselor. Din cauza dimensiunii reduse a setului de date, fiecare clasă din seturile de validare și test conține un număr mic de exemple, aproximativ 5–6 imagini per clasă, ceea ce influențează stabilitatea statistică a evaluării finale.

Pentru reducerea dezechilibrului de clasă în setul de antrenare este utilizat un `WeightedRandomSampler`, care asigură selectarea uniformă a exemplurilor din fiecare clasă în timpul antrenării.

Modelul ResNet-18 este inițializat cu ponderi pre-antrenate, iar straturile convoluționale de bază sunt înghețate parțial pentru a păstra reprezentările generale învățate anterior. Sunt deblocate doar ultimul bloc convoluțional (layer4) și stratul complet conectat, care este înlocuit cu un clasificator personalizat format dintr-un strat intermediar de 256 de neuroni, funcție de activare ReLU și dropout de 0.4, urmat de stratul final de clasificare în 5 clase.

Antrenarea este realizată utilizând optimizatorul Adam cu rate de învățare diferențiate: o rată mai mică pentru layer4 și una mai mare pentru stratul fully connected. Funcția de cost utilizată este `CrossEntropyLoss` cu label smoothing, iar programarea ratei de învățare este realizată printr-un scheduler de tip cosine annealing.

2.2.1 Dinamică de antrenare și analiza funcției de pierdere

Evoluția procesului de antrenare este ilustrată în Figura următoare, unde sunt prezentate curbele de loss pentru setul de antrenare și setul de validare pe parcursul celor 20 de epoci.




Figura 2.3: Reprezentarea funcției de pierdere pentru antrenare și validare.

Se observă că, în fazele inițiale, modelul înregistrează o scădere rapidă a funcției de pierdere, atât pe setul de antrenare, cât și pe cel de validare, indicând o capacitate bună de învățare a reprezentărilor relevante. Ulterior, curba de training prezintă fluctuații moderate, fenomen explicabil prin dimensiunea redusă a datasetului și prin utilizarea augmentării de date, care introduce variații stocastice suplimentare în distribuția imaginilor.

În schimb, curba de validare se stabilizează relativ rapid, în jurul epocilor 14–16, sugerând o convergență timpurie a modelului. Cel mai bun rezultat este obținut în epoca 18, unde se înregistrează valoarea minimă a funcției de pierdere pe setul de validare, indicând configurația optimă a parametrilor învățați.

2.2.2 Evaluare pe setul de test și analiza rezultatelor

După selectarea modelului optim, acesta este evaluat pe setul de test, obținând o acuratețe de aproximativ 75%.

Rezultatele indică în continuare o tendință de confuzie între clasele *Peat Soil* și *Black Soil*, fenomen observat și în abordarea clasică, explicat prin similaritățile cromatice dintre aceste categorii. În plus, dezechilibrul inerent al dimensiunii reduse a datasetului influențează semnificativ stabilitatea estimărilor, fiecare clasă din setul de test fiind reprezentată de un număr mic de exemple.

De asemenea, trebuie subliniat faptul că evaluarea în cadrul acestui experiment se realizează pe un split fix 70–15–15, ceea ce conduce la un număr redus de imagini per clasă în seturile de validare și test. Acest aspect afectează robustețea statistică a metricilor obținute, în special în comparație cu abordarea bazată pe Random Forest, unde evaluarea a fost realizată pe un set de test diferit ca structură și distribuție.

În ciuda acestor limitări, modelul ResNet-18 demonstrează capacitatea de a învăța reprezentări discriminative relevante pentru clasificarea tipurilor de sol, confirmând eficiența abordărilor bazate pe transfer learning în scenarii cu date limitate.




Figura 2.4: Matricea de confuzie - ResNet18.

Classification Report:				
	precision	recall	f1-score	support
Black Soil	0.67	1.00	0.80	6
Cinder Soil	0.80	0.80	0.80	5
Laterite Soil	0.75	0.75	0.75	4
Peat Soil	0.50	0.20	0.29	5
Yellow Soil	1.00	1.00	1.00	4
accuracy			0.75	24
macro avg	0.74	0.75	0.73	24
weighted avg	0.73	0.75	0.72	24

Figura 2.5: Raportul de clasificare - ResNet18.

2.3 DenseNet121

Arhitectura DenseNet121 a fost utilizată ca model de referință în cadrul unei a doua abordări bazate pe învățare profundă, având ca scop evaluarea performanței unei rețele convoluționale dense în condițiile unui set de date de dimensiune redusă. Modelul a fost inițializat cu ponderi pre-antrenate pe ImageNet, iar stratul de clasificare final a fost adaptat pentru cele cinci clase de sol. În această configurație, backbone-ul rețelei a fost înghețat, astfel încât procesul de învățare s-a concentrat exclusiv pe capul de clasificare, reducând semnificativ riscul de overfitting.

Antrenarea a fost realizată pe un număr de 20 de epoci, utilizând un batch size de 32, augmentare intensă a datelor și regularizare prin dropout și penalizare L2. De asemenea, a fost aplicată label smoothing pentru stabilizarea distribuțiilor de probabilitate și pentru evitarea predicțiilor excesiv de încrezătoare.

2.3.1 Analiza curbelor de antrenare

Din analiza curbelor de pierdere (loss), se observă că eroarea pe setul de antrenare prezintă un comportament oscilant, dar cu o tendință general descendentă. Această instabilitate este explicabilă prin combinarea mai multor factori: dimensiunea redusă a setului de date, utilizarea unei augmentări agresive și variațiile semnificative între batch-uri succesive. În contrast, curba de validare este considerabil mai stabilă, indicând faptul că modelul învață caracteristici generalizabile și nu doar particularități ale datelor de antrenare.

Totuși, se observă o diferență relativ constantă între loss-ul de antrenare și cel de validare, de aproximativ 0.5, ceea ce sugerează o formă moderată de overfitting. Această diferență nu este critică, însă indică faptul că modelul începe să memoreze parțial structuri specifice setului de antrenare, în ciuda regularizării aplicate.




Figura 2.6: Reprezentarea funcției de pierdere pentru antrenare și validare - DenseNet121.

2.3.2 Analiza matricei de confuzie

Analiza matricei de confuzie evidențiază diferențe semnificative în capacitatea de separare a claselor. Clasele *Black Soil* și *Cinder Soil* au înregistrat cele mai ridicate rate de clasificare incorectă, fiind frecvent confundate cu alte tipuri de sol cu caracteristici vizuale similare.

Comparativ cu arhitectura ResNet18, DenseNet121 a demonstrat o capacitate mai bună de extragere a caracteristicilor discriminative globale, însă a manifestat o inversare a pattern-ului de confuzie între clasele *Black Soil* și *Peat Soil*. Dacă în cazul ResNet18, *Peat Soil* era frecvent clasificat ca *Black Soil*, în cazul DenseNet121 se observă fenomenul invers, ceea ce sugerează o sensibilitate diferită a reprezentărilor interne în raport cu variațiile de textură și luminozitate.

Acest comportament indică faptul că, deși DenseNet121 reușește o separare mai fină a caracteristicilor la nivel de reprezentare, decizia finală a clasificatorului rămâne influențată de similarități vizuale puternice între clasele cu conținut organic ridicat și variații de culoare suprapuse, în special în regiunile de tranziție dintre *Black Soil* și *Peat Soil*.




Figura 2.7: Matricea de confuzie - DenseNet121.

	precision	recall	f1-score	support
Black Soil	0.67	0.33	0.44	6
Cinder Soil	1.00	0.40	0.57	5
Laterite Soil	0.60	0.75	0.67	4
Peat Soil	0.50	0.80	0.62	5
Yellow Soil	0.67	1.00	0.80	4
accuracy			0.62	24
macro avg	0.69	0.66	0.62	24
weighted avg	0.69	0.62	0.60	24

Figura 2.8: Raportul de clasificare - DenseNet121.

Concluzii și direcții viitoare

Lucrarea de față a analizat comparativ două paradigme fundamentale de clasificare a imaginilor în contextul tipurilor de sol: o abordare clasică bazată pe reprezentarea Bag of Visual Words (BoVW) combinată cu un clasificator Random Forest și o abordare modernă bazată pe învățare profundă, utilizând rețele neuronale convoluționale de tip ResNet-18, respectiv DenseNet.

Rezultatele experimentale indică faptul că ambele direcții metodologice sunt capabile să atingă performanțe similare din punct de vedere al acurateței globale, în ciuda diferențelor semnificative de complexitate arhitecturală și mod de reprezentare a datelor. În particular, modelele de tip deep learning (ResNet-18 și DenseNet) au obținut performanțe apropiate în termeni de acuratețe, însă ResNet-18 a demonstrat o stabilitate superioară în procesul de optimizare, reflectată printr-o funcție de pierdere mai bine controlată și o tendință mai redusă de overfitting.

În contrast, DenseNet, deși competitiv din punct de vedere al acurateței finale, a prezentat o variabilitate ușor mai ridicată în dinamica loss-ului, ceea ce sugerează o sensibilitate mai mare la dimensiunea redusă a setului de date și la distribuția relativ limitată a exemplilor de antrenare. Acest aspect este relevant în contextul în care datasetul utilizat este restrâns, iar variațiile statistice între batch-uri pot influența semnificativ procesul de generalizare.

Comparativ, abordarea bazată pe BoVW și Random Forest a demonstrat o eficiență surprinzătoare, atingând o acuratețe de aproximativ 80%, ceea ce confirmă faptul că, pentru probleme dominate de texturi și variații cromatice, reprezentările statistice ale descriptorilor locali pot fi suficient de discriminative chiar și în absența unor modele profunde.

Din perspectiva generală a rezultatelor, se poate observa că diferențele dintre abordări nu sunt semnificative în termeni de acuratețe absolută, însă diferă în ceea ce privește stabilitatea antrenării, sensibilitatea la date și comportamentul în raport cu overfitting-ul. Modelele bazate pe transfer learning oferă avantajul unei generalizări mai robuste, însă rămân dependente de volumul și diversitatea datasetului utilizat.

Direcții viitoare

O direcție importantă de extindere a acestei lucrări o reprezintă utilizarea tehnicilor de validare mai robuste statistic, în special K-fold Cross-Validation. Această metodă ar permite o evaluare mai stabilă a performanței modelelor, în special în scenarii caracterizate de seturi de date mici, unde împărțirea fixă train/validation/test poate introduce variații semnificative în metricile finale.

Prin împărțirea repetată a datelor în mai multe fold-uri și antrenarea iterativă a modelului pe fiecare combinație, K-fold Cross-Validation reduce influența particulară a unui split favorabil sau nefavorabil și oferă o estimare mai fidelă a capacității reale de generalizare. În contextul acestui tip de problemă, unde numărul de exemple este limitat, o astfel de abordare ar putea evidenția mai clar robustețea comparativă a metodelor analizate.

Bibliografie

- [1] Spyros Gidaris, Andrei Bursuc, Nikos Komodakis, Patrick Pérez, and Matthieu Cord. Learning representations by predicting bags of visual words, 2020.
- [2] Gilles Louppe. Understanding random forests: From theory to practice, 2015.
- [3] Stack Overflow. Using a custom resnet18 code in pytorch transfer learning. <https://stackoverflow.com/questions/68948922/using-a-custom-resnet18-code-in-pytorch-transfer-learning>. Accesat la 29 mai 2026.
- [4] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks, 2018.